

# Izvještaj

## Motivacija

AI sistemi često zahtijevaju velike količine podataka kako bi postigli visoke performanse. Međutim, u mnogim realnim scenarijima jednostavno nema dovoljno podataka za adekvatno treniranje i evaluaciju.

### Stvarni scenariji:

- **Medicinska dijagnostika:** Ako model prepozna 1000 bolesti, a pacijent dođe sa 1001. koju model nikad nije vidio, cilj je da sistem kaže "ne znam" umjesto postavljanja pogrešne dijagnoze s visokom sigurnošću<sup>1</sup>.
- **Autonomna vožnja:** U nepredviđenim situacijama (npr. slon na cesti), važno je da model prepozna nepoznat objekt i reaguje oprezno radi sigurnosti putnika<sup>2</sup>.
- **Industrijska kontrola kvaliteta:** Sistem mora detektovati nove defekte na proizvodima umjesto da ih klasifikuje u već poznate kategorije<sup>3</sup>.

### Ključni izazovi:

1. **Few-Shot Learning:** Kako naučiti robusne modele sa svega 1–16 uzoraka po klasi? <sup>4</sup>
2. **Out-of-Distribution (OOD) Detection:** Kako prepoznati uzorke koji ne pripadaju nijednoj treniranoj klasi? <sup>5</sup>

**Temeljni kompromis:** Potrebno je balansirati između točnosti na poznatim klasama (ID accuracy) i opreza prema nepoznatim uzorcima (OOD detection), jer modeli sigurni na ID podacima često pokazuju preveliku sigurnost i na OOD podacima<sup>6</sup>.

---

## Definicija problema

**Zadatak:** Few-shot klasifikacija uz detekciju out-of-distribution uzoraka<sup>7</sup>.

### Setup:

- **In-Distribution (ID):** ImageNet-Val dataset (1000 klasa, 50.000 slika)<sup>8</sup>.
- **Out-of-Distribution (OOD):** ImageNet-O dataset (2000 slika, objekti van ImageNet taksonomije)<sup>9</sup>.
- **Few-Shot režim:**  $K \in \{0, 1, 2, 4, 8, 16\}$  uzoraka po klasi<sup>10</sup>.

### Arhitektura:

- **Feature Extraction:** CLIP ViT-B-16 (pre-trained, 512-dimenzionalni embedding)<sup>11</sup>.
- **Classification Heads:**

- 1. **Zero-Shot**: Kosinusna sličnost s tekstualnim embeddingom<sup>12</sup>.
- 2. **Prototype**: Udaljenost do centroida klase<sup>13</sup>.
- 3. **Linear Probe**: Linearna transformacija (512 → 1000)<sup>14</sup>.
- 4. **Gaussian**: Gaussova diskriminativna analiza s Mahalanobisovom udaljenosti<sup>15</sup>.

**Metrike:**

- **ID**: Accuracy (točnost) i ECE (Expected Calibration Error)<sup>16</sup>.
- **OOD**: AUROC (Area Under ROC) i FPR@95 (False Positive Rate pri 95% TPR)<sup>17</sup>.

# 1. Detaljna analiza rezultata

## 1.1 Neuspjeh Gaussian Heada

Gaussian head potpuno zakazuje pri **K=1** (točnost svega **0.11%**), dok pri **K=16** postiže visoku točnost (68.9%), ali lošu OOD detekciju (AUROC=0.571)<sup>18</sup>.

**Uzroci:**

- **Prokletstvo dimenzionalnosti**: 262.144 parametara kovarijanse naspram samo jednog uzorka pri K=1 čini matricu singularnom<sup>19</sup>.
- **Kršenje pretpostavke**: Klase u CLIP prostoru ne dijele istu strukturu kovarijanse (neke su uske, neke široke)<sup>20</sup>.
- **Overconfidence**: Model prelazi iz potpune nesigurnosti u ekstremnu sigurnost bez "sredine", čineći ID i OOD distribucije identičnim<sup>21</sup>.

## 1.2 Točnost vs. OOD detekcija

| Metoda       | K=16 Točnost | K=16 AUROC | K=16 FPR@95 |
|--------------|--------------|------------|-------------|
| Linear Probe | 52.5%        | 0.752      | 86.6%       |
| Prototype    | 62.9%        | 0.782      | 79.3%       |
| Gaussian     | 68.9%        | 0.571      | 91.5%       |

- **Linear Probe** je uspješan pri malom K zbog diskriminativnog treniranja, ali je previše samouvjeren na OOD podacima<sup>22</sup>.
- **Prototype** dominira pri K≥8 jer čuva CLIP semantiku i bolje razdvaja ID od OOD distribucija<sup>23</sup>.

## 1.3 Kalibracija (ECE)

Prosječni ECE je 0.413, što ukazuje na lošu kalibraciju<sup>24</sup>. Pri K=16, Gaussian je najbolje kalibriran (0.299), dok je Prototype najlošiji (0.628), što znači da Prototype zahtijeva

## 1.4 Zero-Shot Baseline

Zero-shot CLIP (Accuracy: 58.3%, AUROC: 0.750) nadmašuje sve metode dok se ne dosegne **K≥8** uzoraka<sup>26</sup>.

## 2. Konačni sažetak rezultata

Performanse po metodama (prosjek):

| K-shot | Metoda      | Accuracy | AUROC | FPR@95 | ECE   |
|--------|-------------|----------|-------|--------|-------|
| 0      | ZeroShot    | 58.3%    | 0.750 | 84.3%  | 0.582 |
| 1      | LinearProbe | 30.2%    | 0.693 | 89.5%  | 0.301 |
| 1      | Prototype   | 29.6%    | 0.692 | 89.9%  | 0.294 |
| 1      | Gaussian    | 0.1%     | 0.500 | 100%   | 0.000 |
| 4      | Prototype   | 52.0%    | 0.760 | 82.2%  | 0.519 |
| 16     | Prototype   | 62.9%    | 0.782 | 79.3%  | 0.628 |
| 16     | Gaussian    | 68.9%    | 0.571 | 91.5%  | 0.299 |

### Zaključci:

1. **Gaussian Head** je neupotrebljiv pri K=1 zbog visoke dimenzionalnosti<sup>27</sup>.
2. **Zero-shot CLIP** je najbolji izbor za vrlo mali broj podataka (K < 8)<sup>28</sup>.
3. **Prototype Head pri K=16** nudi najbolji balans između točnosti i sigurnosti detekcije<sup>29</sup>.
4. **Distance-based metode** u CLIP semantičkom prostoru nadmašuju diskriminativne metode u few-shot OOD zadacima<sup>30</sup>.

### Ključna poruka:

"Prototype head sa K=16 uzoraka postiže najbolju ravnotežu između ID točnosti (62.9%) i OOD detekcije (AUROC=0.782), nadmašujući zero-shot CLIP za 4.6% u točnosti." <sup>31</sup>