

Generativne glave na CLIP značajkama za klasifikaciju s malo primjera

Dominik Agejev, Ivan Skukan, Ian Marković,
Lucija Petkoviček, Leonora Đemaili



Motivacija

- Kako pouzdano klasificirati primjere koji su izvan distribucije (OOD primjeri)?
- Primjer:
 - AI sustav treniran na 1000 bolesti, a pacijent ima rijetku bolest
 - Hoće li sustav reći "ne znam" ili dati pogrešnu dijagnozu?
- Primjer:
 - AI sustav treniran za autonomnu vožnju u gradskim uvjetima
 - Slon pobjegne iz zoološkog. Što će sustav zaključiti kad ga vidi?


Definicija problema



- CLIP određuje koliko je slika slična tekstu, ali ne povlači granicu između poznatih (ID) i nepoznatih (OOD) klasa
- Zato treniramo klasifikacijske glave koje treniramo na zamrznutom CLIP-u
- ImageNet-1k za podatke iz distribucije
- ImageNet-O za podatke van distribucije (OOD)
- K-shots (broj označenih primjera klase za treniranje glave): 0,1,2,4,8,16

Što je CLIP?

- Contrastive Language-Image Pretraining
- Model povezuje slike i tekst u zajednički semantički prostor:
 - "A photo of a dog" -> blizu slike psa u prostoru ugrađivanja
- Arhitektura:
 - Encoder za sliku i encoder za tekst
 - Učenje na temelju kontrasta vektora slike i teksta
- Zašto CLIP?
 - Predtreniran na 400m slika-tekst parova
 - Zero-shot - može klasificirati s 0 primjera (baseline daljnje analize)



Klasifikacijske glave

- Zero-shot:
 - Ugrađeni tekst: "A photo of {class}" za svih 1000 klasa
 - Uzimamo prosjek više promptova
 - Ne treniramo
- Linearna glava:
 - Regularizirani linearni model klasificira ugrađivanja
- **Prototipna glava:**
 - Temelji se na kosinusnoj udaljenosti
 - Klasifikacija: najbliži prototip
 - OOD: daleko od svih prototipa
- **Gaussova glava:**
 - Za svaku klasu učimo parametre
 - Prepostavljamo zajedničku kovarijacijsku matricu
 - Problem: 512x512 parametara

Diskriminativne

Generativne

Ključna pitanja


Koja metoda
najbolje balansira
ID točnost i OOD
detekciju?

Koliko primjera je
potrebno da
nadmašimo zero-
shot?

Ako neka metoda
ne uspijeva, zašto?


Pregled rezultata

- Zero-shot je na 58.3%
- Gaussian neuspješan za OOD
- Prototype je najbolji za OOD AUROC
- Prototype je najbolji za FPR@95 (Niže je bolje)
- Prototype ima najbolji trade-off




Pregled rezultata

- Zero-shot je na 58.3%
- Gaussian neuspješan za OOD
- Prototype je najbolji za OOD AUROC
- Prototype je najbolji za FPR@95 (Niže je bolje)
- Prototype ima najbolji trade-off




Pregled rezultata - zero-shot

- Zero-Shot (K=0): 58.3% accuracy
- Few-Shot (K=4): 52.0% accuracy (Prototype)
- Idealno bi distribucije bile potpuno odvojene
- Slaba sigurnost!




Pregled rezultata - Gaussian

- Gaussian daje najveću ID točnost:
 - 16 uzoraka po klasi daje dovoljno informacije za procjenu distribucije
 - Model je vrlo siguran u svoje (često krive) predikcije za $K = 16$.
 - Skoro pa ne razdvaja distribucije
 - Za $K=1$ ne razdvaja i ima slabu sigurnost (ne zna što se događa)




Pregled rezultata - Gaussian

- Gaussian daje najveću ID točnost:
 - 16 uzoraka po klasi daje dovoljno informacije za procjenu distribucije
 - Model je vrlo siguran u svoje (često krive) predikcije za $K = 16$.
 - Skoro pa ne razdvaja distribucije
 - Za $K=1$ ne razdvaja i ima slabu sigurnost (ne zna što se događa)



Pregled rezultata - Prototip (K=16)

- ID točnost je 62.9%
- Marginalna ali konzistentna poboljšanja
- Bolja OOD detekcija – distribucije malo udaljenije
- Još uvijek je veliko preklapanje i mala sigurnost!



Sažetak

- Prototype glava jedina nadmašuje zero-shot uz $K \geq 8$
- Slaba sigurnost vjerojatno je uzrokovana velikim brojem klasa (ImageNet je težak)
- Gaussian:
 - $K=1$ - Prokletstvo dimenzionalnosti (262k parametara)
 - $K > 1$ - Jaka samouvjerjenost - misli da je sve sigurno ImageNet-1k
- Linear probe:
 - Lošiji rezultati od zero-shot
 - Unakrsna entropija optimira točnost, a ne sigurnost



Hvala na pažnji!

- Pitanja?

Izvori

- CLIP slike: <https://medium.com/@paluchasz/understanding-openais-clip-model-6b52bade3fa3>
- ImageNet slika:
https://www.tensorflow.org/datasets/catalog/imagenet2012_subset